



Endangered Archaeology in the Middle East & North Africa



Durham University

ARCADIA

تعلم كشف EAMENA الآلي للتغير بشكل تلقائي (MLACD)

شرح خطوات استخدام البرنامج

EAMENA Machine Learning Automated Change Detection (MLACD)

Training Documentation

تطوير و إعداد د. أحمد محمود

مراجعة د. نيكول شيلدريك

ترجمها إلى العربية د. أحمد بوزيان

النسخة الأولى: أكتوبر 2023

النسخة الثانية: سبتمبر 2025

قائمة المصطلحات

EAMENA إيمينا: الآثار المهددة بالاندثار في الشرق الأوسط وشمال أفريقيا

GEE : محرك جوجل إيرث

Machine Learning (ML) : التعلم الآلي

Automated Change Detection (ACD) : الكشف الآلي أو التلقائي للتغيير

JavaScript : لغة برمجة JavaScript (JV)

Training Sample (TS) : عينة تدريب

Script النص البرمجي: شفرة برنامج يتضمن سلسلة من العمليات والوظائف

Glossary

EAMENA: Endangered Archaeology in the Middle East and North Africa

GEE: Google Earth Engine

ML: Machine Learning

ACD: Automated Change Detection

JV: JavaScript

TS: Training Sample

Script: A program code with a sequence of processes and functionalities

Automated Change Detection (ACD)


الكشف التلقائي للتغيرات في المواقع الأثرية (ACD)

Introduction 1 مقدمة

يعد الكشف الآلي عن التغيرات باستخدام تطبيق إيمينا للكشف الآلي عن التغيرات (EAMENA MLACD) أداة طورها باحثو مشروع EAMENA آلية يتم من خلالها مراقبة التغيرات والتهديدات في المواقع الأثرية وحلوها بسرعة عبر استخدام صور الأقمار الاصطناعية، وللحصول على فهم شامل للتطبيق، يرجى الاطلاع على المقال الكامل عن هذا الموضوع المتوفّر عبر الرابط التالي:

<https://doi.org/10.1016/j.rsase.2024.101396>.

يستخدم التطبيق خدمة الحوسبة السحابية لمحرك غوغل Google Earth Engine وقد تم تطويرها باستخدام لغة برمجة JavaScript وخوارزمية التعلم الآلي (Random Forest) لمعالجة سلسلة زمنية من صور الأقمار الاصطناعية، وإنشاء خرائط تصنيف للأراضي بهدف الكشف عن التغيرات والتهديدات التي تتعرض لها المواقع الأثرية مع مرور الوقت (انظر الشكل 1).



. الشكل 1: خطوات عمل EAMENA MLACD

2 المتطلبات Pre-requisites

لاستخدام EAMENA MLACD، ستحتاج إلى حساب في Google Earth Engine.


- فتح حساب والدخول في Google Earth Engine، اتبع الإرشادات الواردة في الرابط التالي:
<https://signup.earthengine.google.com/#/>
- قد يستغرق الأمر في بعض الأحيان عدة أيام حتى يتم القبول والمموافقة على طلب فتح الحساب

3 البدء Getting Started

بمجرد الموافقة على طلبك، انتقل إلى <https://code.earthengine.google.com/> للوصول إلى محرر الكود حيث سيتم البدء بتشغيل تطبيق MLACD.

قام فريق EAMENA بإعداد حالة دراسة محددة مسبقاً لـ MLACD ويمكنك الوصول إليها على الرابط أدناه:

- Bani Walid: <https://code.earthengine.google.com/943a52e4f1c9a1ec52558198a784da0b>.
 ولتوسيع خطوات العمل ستستخدم هذه الوثيقة هذه الحالة الدراسية التي جرت في منطقة بني وليد في غرب ليبيا.
 انقر على هذا الرابط المذكور أعلاه لفتح النص المبرمج الخاص بمنطقة بني وليد.



- انقر فوق "Save" لحفظ النص البرمجي في مكان حفظ GEE الذي خصصته
- أعطه اسمًا مثل "EAMENA_MLACD" حتى يمكنك الرجوع إليه

- يمكنك دائمًا العثور على أحدث إصدار من نص MLACD المبرمج على صفحة GitHub EAMENA GitHub:
<https://github.com/eamena-project>,
<https://github.com/eamena-project/EAMENA-MachineLearning-ACD>

لبدء استخدام التطبيق، هناك العديد من العناصر والمعايير parameters التي يجب تحديدها وتعديلها في نص JavaScript المبرمج الخاص بالتطبيق EAMENA MLACD

تنقسم آلية العمل إلى ثلاث مراحل رئيسية:

- تحديد المتغيرات variables والمدخلات inputs .
- تصنيف الصور وتحليلها.
- تحديد التهديدات للموقع الأثري.

ملاحظة: إذا كنت ترغب في تعديل النص المبرمج الحالي وتكييفه مع دراسة حالة جديدة، يُرجى الرجوع إلى القسم 9 "خطوات تكيف أداة MLACD مع دراسات حالة جديدة"

4 الخطوة 1: تحديد المتغيرات والمدخلات Defining variables and inputs

سوف تحدد في المرحلة الأولى ثلاثة أشياء:

1. منطقة الدراسة.
2. الموقع الأثري المراد التقصي عنها.
3. عينات التدريب.
4. مؤشرات العرض visualisation parameters.
5. النطاقات bands (صور جوية مأخوذة بأطيفات ضوئية مختلفة) المستخدمة في التحليل.
6. قيم وأسماء الرسوم البيانية والمخرجات الأخرى.

ستسهل في المراحل التالية كل هذه المدخلات والمتغيرات المحددة الآلية التلقائية واستخراج النتائج من النص المبرمج.

1.4 تحديد منطقة الدراسة Defining the Study Area

ستأتي النصوص المعدّة سلفاً مع منطقة الدراسة.

إذا كنت تود التقصي عن منطقة دراسة جديدة، فستحتاج إلى تغيير ذلك عن طريق حذف منطقة_study_area الحالية وإدخال منطقة دراسة خاصة بك بواسطة إحدى الطريقيتين التاليتين.

1.1.4 الطريقة 1: الرسم من خلال أداة الهندسة Draw with the Geometry Tool

يمكن رسم منطقة الدراسة يدوياً باستخدام أداة الهندسة **Geometry tool** الموجودة في الزاوية العلوية اليسرى من لوحة خريطة GEE.

- قم بإنشاء طبقة هندسية جديدة برسم شكل مضلع حول منطقة الدراسة إما باستخدام أداة المستطيل أو المضلع



- لتغيير خصائص الطبقة الجديدة، قم بتحريك الفأرة فوق مربع "Geometry Imports" وافتح أداة التهيئة بالنقر على أيقونة الترس
- قم بتغيير اسم الشكل الهندسي إلى 'Study_Area'
- احتفظ بنوع الميزة أو الظاهرة feature type تحت 'Import as' as 'Geometry'
- وسوف يظهر في الواردات Imports الخاصة بك أعلى النص المبرمج

Geometry Imports
 geometry (1 poly)
+ new layer

Configure geometry import

Name

Color

#98ff00

Import as

Geometry

Properties


No properties.

OK
Cancel

2.1.4 الطريقة 2: تحميل ملف الشكل Shapefile Upload

إذا حددت بالفعل منطقة دراستك في نظام المعلومات الجغرافية ولديك المنطقة في شكل ملف Shapefile، يمكنك كذلك تحميله مباشرة إلى GEE.

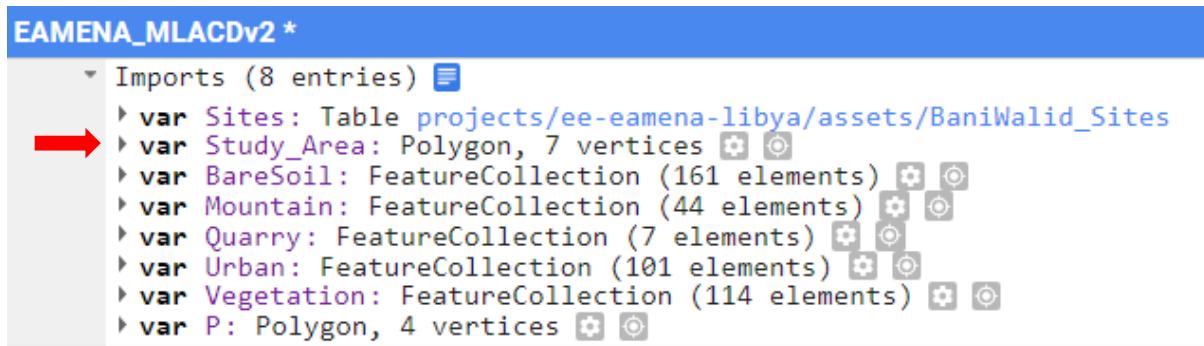
- في لوحة محرر كود GEE code editor الرئيسية، انتقل إلى علامة التبويب الأصول Assets واختر NEW.
- تحت .Shape files (.shp, .shx, .dbf, .prj, or .zip) ، انقر فوق Table Upload.
- اتبع التعليمات لتحميل ملف الشكل shapefile الخاص بك واعطه اسمًا يمكن تذكره.
- تأكد من أنك قد اخترت كافة امتدادات ملف الشكل shapefile أو اختر المجلد المضغوط zip folder الذي يحتوي على كافة امتدادات الملفات الداعمة لملف الشكل .shapefile.



الشكل 2: إضافة الأصول "البيانات" assets في مشاريع GEE.

- بمجرد تحميله إلى قائمة الأصول Assets الخاصة بك، نشطه بالنقر عليه ثم انقر فوق "Import" لاستيراده ونقله إلى النص البرمجي script الخاص بك.
- عندما تقوم باستيراده، ستراه يظهر في الجزء العلوي من النص البرمجي المسمى "table".
- يجب عليك تغيير الاسم إلى ".Study_Area".

```
// Study_Area = Study_Area.geometry(); → study_Area = Study_Area.geometry();
```



ملاحظات هامة لكلا الطريقتين:

- لا بد من تسمية الميزة أو الظاهره لمنطقة الاهتمام الخاصة بك باسم "Study_Area" حيث يتم استخدام هذه التسمية في كود JavaScript EAMENA MLACD لتنفيذ مهام أخرى.
- لكي تجعل MLACD تعمل، يجب أن تغطي منطقة الدراسة التي تحددها جميع الموقع الأثري المرغوب تحليلها، والتي ستقوم بتحديدها في القسم التالي:

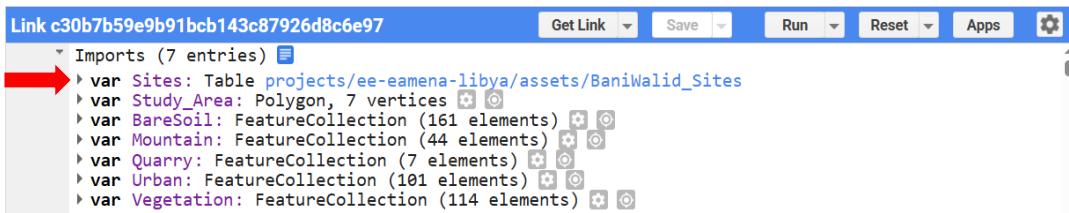
2.4 تحديد المواقع الأثرية المراد التقصي عنها Defining the Archaeological Sites under Investigation

تأتي النصوص المبرمجة المعدة مسبقاً محملة بمجموعة من المواقع الأثرية ضمن مناطق الدراسة المحددة سلفاً.
إذا كنت تريدها عن مجموعة بيانات موقع جديدة، فستحتاج إلى تغيير ذلك عن طريق حذف الاستيراد المسمى "Sites" في الجزء العلوي من النص المبرمج وإضافة المجموعة الخاصة بك، باستخدام إحدى الطريقتين التاليتين.

1.2.4 الطريقة 1: تحميل ملف الشكل Shapefile Upload

اتبع الطريقة نفسها التي استخدمتها في القسم الأخير لتحميل ملف شكل منطقة الدراسة Study Area shapefile


- قم بتحميل ملف الشكل asset shapefile كأصل asset وانقله إلى النص المبرمج الخاص بك باستخدام الإرشادات نفسها التي اتبعتها لتحميل منطقة الدراسة في القسم 1.1.4 أعلاه
- بمجرد استيراد الجدول إلى نصك المبرمج، يجب عليك تغيير الاسم إلى "Sites"



2.2.4 الطريقة 2: الرسم بأداة الشكل الهندسي Draw with the Geometry Tool

وهذه طريقة أخرى بدالة تمكن من رسم أماكن المواقع يدوياً باستخدام أداة الهندسة Geometry tool الموجودة في الزاوية اليسرى العليا من لوحة خريطة GEE.

- استخدم أداة الشكل الهندسي Geometry tool لوضع نقطة Point عند كل موقع أثري تود تحليله
- عندما يتم وضع نقطة على كل موقع، قم بتحريك الفأرة فوق مربع "Geometry Imports" وافتح أداة التهيئة من خلال النقر على أيقونة الترس
- قم بتغيير الاسم إلى "Sites" وقم بتغيير النوع تحت Import as إلى "Feature Collection"
- انقر فوق "OK"، وستظهر مواقعك في الجزء العلوي من النص المبرمج ضمن Imports الخاصة بك



ملاحظات هامة لكلتا الطريقتين:

- يجب عليك تصنيف الموقع ووسمها ك "Sites" حيث يتم استخدام هذه التسمية في كود JavaScript EAMENA لتنفيذ مهام أخرى.

3.4 تحديد عينات التدريب Defining the training samples

تعمل أداة MLACD من خلال إنشاء سلسلة من خرائط تصنيف استخدامات الأرضي وغطاء الأرض لمنطقة الاهتمام وال فترة الزمنية التي يحددها المستخدم.

- ليتسع إنشاء خرائط تصنيف سطح الأرض، يجب علينا أولاً "تدريب train" النص البرمجي للتعرف على أنواع غطاء سطح الأرض المختلفة التي نريد تحديدها، على سبيل المثال، النباتات والأرض الجرداء ومناطق العمارة، وما إلى ذلك
- عن طريق إنشاء عينات التدريب Training Samples.
- ستكون كل عينة تدريب موقعاً ممثلاً لنوع من أنواع الغطاء الأرضي يمكن تمييزها من صورة القمر الصناعي (مثل مناطق العمارة، الغطاء النباتي، إلخ).

لإنشاء عينات التدريب، انتقل ضمن محرر الكود المبرمج Code Editor إلى القسم 1 تحديد المتغيرات والمدخلات: **Defining Variables and Inputs**، ثم قم بالتمرير لأسفل إلى القسم المسمى تحديد عينات التدريب ومتغيرات الأنواع **Define Training Samples and Classification Variables** (من السطر 23 إلى السطر 29).

- يمكن إنشاء نماذج التدريب كأشكال متعددة الأضلاع polygons أو نقاط points
- يوصى هنا باستخدام الأشكال متعددة الأضلاع Polygons لأنها طريقة أسرع لجمع عدد كبير من العينات لكل نوع من أنواع غطاء سطح الأرض.
- نستخدم أسلوب المعاينة العشوائية الطبقية لتوليد نقاط العينات من مجموعة مضلعات عينات التدريب التي قدمها المستخدم.

1.3.4 تحضير المتغيرات في النص البرمجي Prepare the variables in the script

تُحدد عينات التدريب فئات الغطاء الأرضي التي ستستخدمها أداة MLACD في عملية التصنيف. الخطوة الأولى بالنسبة لمنطقة دراستك هي تحديد عدد أنواع الغطاء الأرضي المختلفة الموجودة وأيها ترغب في تصنيفها. قمنا في مثال بني وليد بتحديد خمسة أنواع.

يجب أن تتضمن كل عينة تدريب ما يلي:

1. مجموعة بيانات عينات التدريب المجمعة؛ وهي FeatureCollection تمثل نوع الغطاء الأرضي (مثل: التربة الجراء، الجبال، المحاجر، مناطق العمران، الغطاء النباتي). ويمكن أن تكون هذه المجموعة:
 - تم استيرادها إلى النص المبرمج، أو
 - تم إنشاؤها باستخدام أداة الرسم الهندسي (Geometry Drawing Tool) في Google Earth Engine (GEE)
2. لون: رمز اللون السادس عشر (مثلا: '#fffecc3') المستخدم لتصوير إحدى الأنواع في خرائط المخرجات.
 - يمثل كل رمز لون في المثال أعلى لوناً تم تحديده مسبقاً لمثال بني وليد
 - يمكنك نسخ رمز اللون من أداة الرسم الهندسي geometry tool لكل طبقة عينة تدريب Training Layer
3. وسم Label: اسم وصفي للنوع (مثل تربة جراء 'BareSoil'، جبال 'Mountain'، محجر 'Quarry'، مناطق عمران 'Urban'، غطاء النباتي 'Vegetation'). يتم استخدام هذا الوسم تلقائياً في عملية التصنيف وفي مفاتيح خرائط النتائج.

```
22 // // Define the training samples datasets, colours and labels for each class in your case study
23 var trainingClasses = [
24   {TrainingSample: BareSoil, color: '#fffecc3', label: 'BareSoil'}, // class 1
25   {TrainingSample: Mountain, color: '#170821', label: 'Mountain'}, // class 2
26   {TrainingSample: Quarry, color: '#c7c6c5', label: 'Quarry'}, // class 3
27   {TrainingSample: Urban, color: '#cdc2a8', label: 'Urban'}, // class 4
28   {TrainingSample: Vegetation, color: '#118b29', label: 'Vegetation'}, // class 5
29 ];//Add and define additional training samples (e.g., TS: Water, color: '#2591ff', label: 'Water') or remove any class
```

- كيف يتم تحديد عينات التدريب في النص المبرمج:

يتم تنظيم عينات التدريب في مصفوفة trainingClasses . أضف لكل نوع إدخالاً واحداً باستخدام هذه الهيكلية:

```
{TrainingSample: Dataset1, color: '#HEXCODE', label: 'ClassName'}, // class 1
{TrainingSample: BareSoil, color: '#fffecc3', label: 'BareSoil'}, // class 1
```


- تم في هذا المثال تحديد وتعريف طبقة الأرض الجراء (BareSoil) كأول مجموعة بيانات عينات تدريب، باللون 'BareSoil' والوسم '#fffecc3'.
- يمكنك إضافة أنواع أو إزالتها وفق حالة دراستك.
- لتقليل عدد الأنواع، احذف ببساطة سطراً معيناً (مثلاً، حذف النوع 5 إذا كنت بحاجة لأربعة أنواع فقط).
- لإضافة نوع آخر، انسخ سطراً وعدل وفقاً لذلك مجموعة البيانات واللون والوسم (مثلاً، إنشاء النوع 6 لـ 'المياه').('Water')

- بمجرد تحديد عينات التدريب، يقوم النص المبرمج تلقائياً بإنشاء المصفوفات التالية للتصنيف:
 - تحتوي على جميع **FeatureCollections** لمجموعات بيانات عينات التدريب.
 - تحتوي على جميع وسوم الأنواع.
 - تحتوي علىألوان اتصور لكل نوع.

2.3.4 جمع عينات التدريب

سنعمل في هذا القسم كيفية جمع عينات التدريب عن طريق رسم المضلعات باستخدام أداة الرسم الهندسي **Geometry Tool** في GEE

- لكي يعمل النص المبرمج، يجب أن يكون هناك طبقة واحدة لكل نوع غطاء أرضي ترغب في تحديده، بحيث تحتوي كل طبقة على عدة مضلعات.
- كما تم مناقشته في مثال بني وليد في القسم السابق، قمنا بتحديد 5 أنواع، وبالتالي ستتجدد أن هناك خمس طبقات لمجموعات بيانات عينات التدريب تحمل الأسماء المحددة أعلاه، مثل **BareSoil** ، **Mountain** ، **BareSoil** ، **Quarry** ، **Urban** ، **Vegetation**.



إذا قمت بتفعيل طبقة كل من طبقات عينات التدريب واحدة تلو الأخرى، ستلاحظ أن كل طبقة تتكون من عدة مضلعات موزعة عبر منطقة الدراسة.

- كل مضلع يحيط بمنطقة ممثّلة لنوع الذي يعرّفها.
- فعلى سبيل المثال، في طبقة الغطاء النباتي(Vegetation) توجد 114 مضلعاً، يحيط كل منها بمنطقة من الغطاء النباتي، وذلك لـ”تعليم” نموذج التعلم الآلي في النص المبرمج شكل الغطاء النباتي وموقعه.

إذا كنت ترغب في دراسة منطقة مختلفة، فستحتاج إلى حذف طبقات عينات التدريب الحالية وإنشاء طبقات جديدة في منطقة الدراسة الجديدة لتدريب البرنامج النصي على منطقة اهتمامك. يمكنك القيام بذلك باستخدام طرق مختلفة موضحة أدناه.

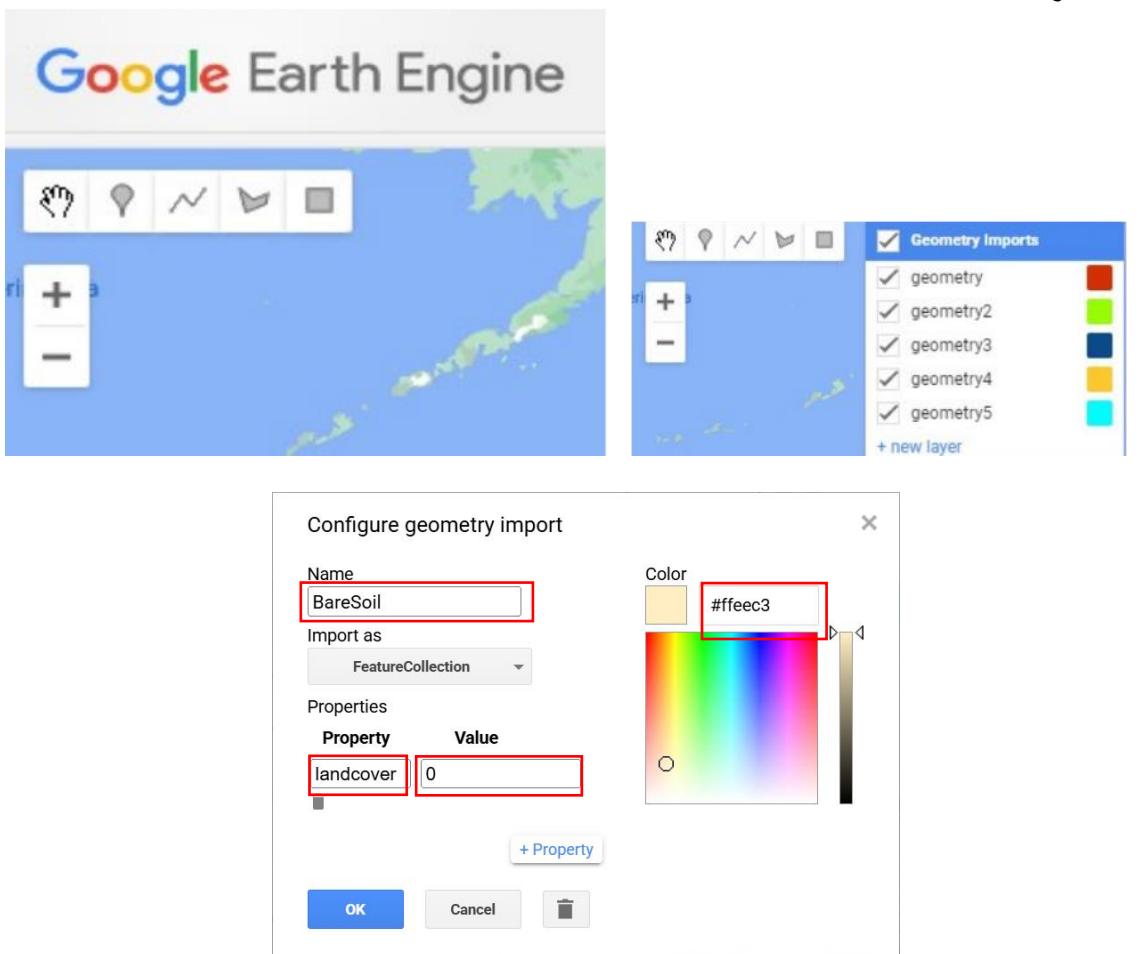
1.2.3.4 جمع عينات التدريب باستخدام أداة الرسم الهندسي في GEE

هذه هي الطريقة التي تم استخدامها لإنشاء عينات التدريب في مثال بني وليد.

لإنشاء طبقة جديدة لعينات التدريب:

- مرر الفأرة فوق علامة تبويب الاستيراد الهندسي (geometry import tab) وانقر على طبقة جديدة (+ new layer).
- مرر الفأرة فوق طبقةك الهندسية الجديدة واضغط على رمز الترس (gear icon) لاختيار تعديل خصائص الطبقة (Edit layer properties).
- قم بتغيير الاسم (Name) إلى اسم النوع الذي ترغب في تحديده.

- يجب أن يكون الاسم مطابقاً تماماً للطريقة التي حددت بها مجموعة بيانات عينات التدريب في القسم السابق، فمثلاً إذا كان النوع 1 BareSoil = class 'BareSoil' ، فيجب أن تسمى الطبقة أيضاً 'Quarry'، Mountain، BareSoil نوع (مثل Quarry، Mountain، BareSoil، Vegetation، Urban، الخ...).
- تحت خيار Import as، اختر 'FeatureCollection' لأن الطبقة تحتوي على عدة معالم.(features). اضغط على زر Property+وقم بتعيين ما يلي:
- اكتب 'landcover' (استخدام أحرف صغيرة، لأن هذا الاسم سيتم استخدامه لاحقاً في النص المبرمج).
- Class Value : خصص رقمياً لكل معلم (مثل: 0، 1، 2، 3، 4 ...). على سبيل المثال: إذا كان النوع 1 هو النوع 1، فامنحه القيمة 0، والنوع 2 = 1 ، النوع 3 = 2 وهكذا.
- اختر لكل نوع لوناً مختلفاً.
- انقر OK.



بعد إنشاء الطبقة، يمكنك البدء في رسم المضلعات .

- ليس هناك قاعدة ثابتة لعدد المضلعات المطلوب - فهذا يعتمد على حجم منطقة الدراسة ومدى انتشار النوع الذي سيتم تصنفيه ضمنها.
- على سبيل المثال، في حالة بني وليد، يحتوي النوع 2 (الجبل Mountain) على 44 مضلاعاً فقط، بينما يتضمن النوع 2 (الأرض الجرداء Bare soil المكشوفة) 161 مضلاعاً.

نصائح عند رسم المضلعات:

- احرص على تضمين أمثلة عدة ممثلة للنوع الذي تقوم بتحديده.
- غير أحجام المضلعات، لكن تجنب جعلها كبيرة جداً - يجب أن يكون كل بكسل pixel داخل المضلع تابعاً بوضوح للنوع المختار.

- وزع المضلعات على كامل منطقة الدراسة لضمان تمثيل مكاني جيد لعينات التدريب.
- استخدم صوراً عالية الدقة في منصة GEE تتوافق مع سنة صور Sentinel-2 التي اخترتها لبيانات التدريب، وتغطي جميع الأنواع المستهدفة.
- تذكر أن جودة عينات التدريب تؤثر بشكل كبير على دقة التصنيف - فكلما كانت عملية الجمع والتحقق أكثر دقة، كانت النتائج أكثر موثوقية.



الشكل 3: مثال لعينات التدريب المجمعة لمناطق الأرض الجردة BareSoil (باللون الأصفر) والمحاجر Quarry (باللون الأحمر)، والتي تمثل نوعي الأرض الجردة ونشاط قلع الحجارة في منطقة بني وليد في ليبيا.

- لتحسين دقة مجموعات بيانات عينات التدريب التي جمعتها، يمكنك تصدير كل مجموعة بيانات تم إنشاؤها في GEE (انظر القسم 8، التصديرات Exports) وتنقيحها باستخدام صور عالية الدقة في Google Earth Pro. استخدم الصور التاريخية (Historical Imagery Panel) المتاحة في Google Earth Pro للتحقق بصرياً من كل مضلع وتعديل أي منها لا يمثل بدقة نوع غطاء الأرض المقصود.
- تتضمن عملية التحقق والدقة الخطوات التالية:
 1. استيراد ملف shapefile المصادر لكل مجموعة بيانات تدريب إلى Google Earth Pro.
 2. تعديل حدود المضلعات عبر خيار الخصائص Properties.
 3. حفظ مجموعة البيانات المعدلة لكل نوع كملف KML جديد.
 4. فتح ملف KML في QGIS.
 5. إعادة تصديره كملف shapefile داخل QGIS.
 6. تحميل ملفات shapefile المصحة مرة أخرى إلى الأصول Assets في Google Earth Engine.
 7. استبدال مجموعات بيانات عينات التدريب الأصلية التي أنشأتها GEE بالإصدارات التي تم التتحقق منها.

2.2.3.4 جمع عينات التدريب باستخدام Google Earth Pro

وهي طريقة بديلة لجمع عينات التدريب برسم المضلعات في Google Earth Pro باستخدام صور مؤرشفة عالية الوضوح، مما يمكن من تحسين دقة التصنيف.

- احفظ المضلعات الخاصة بنوع غطاء أرض واحدة في مجلد، وقم بتصدير المجلد كملف .kml.
- استورد ملف kml الخاص بهذا النوع إلى QGIS وأعد تصديره كملف shapefile.
- أنشئ في QGIS حقلًا جديداً باسم 'landcover' لتخزين قيمة النوع لكل مضلع.

- مثال: إذا كنت تعمل على ملف شكل BareSoil للنوع shapefile على أنه النوع الأول، قم بتعيين القيمة 0 لجميع المضلعات في حقل "غطاء الأرض landcover". النوع الثاني ستكون القيمة 1، النوع الثالث = 2 ، وهكذا.
- قم بتحميل ملف الشكل shapefile لعينات التدريب الخاصة بك إلى **GEE Assets** باستخدام الطريقة الموضحة في القسم 1.2.4
- استورد ملف الشكل shapefile إلى النص البرمجي الخاص بك وأعد تسمية الجدول في استيرادات **Imports** النص البرمجي بما يتوافق مع اسم مجموعة بيانات عينات التدريب (مثل Vegetation ، BareSoil ،).
- يجب أن يتطابق الاسم تماماً مع ما تم تحديده في القسم 1.3.4
- كرر هذه العملية لكل نوع على حدة.
- ملاحظة: عينات التدريب المستوردة بهذه الطريقة لن تظهر كطبقات هندسية مرئية على الخريطة في GEE، لكنها ستظل تعمل بشكل صحيح ضمن سير العمل الخاص بك.

3.2.3.4 جمع عينات التدريب ميدانياً

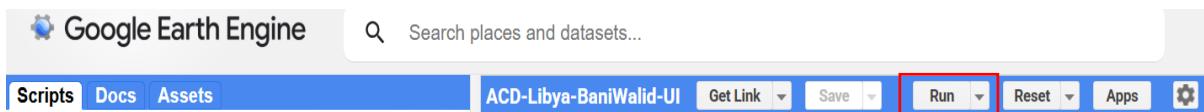
الطريقة الثالثة هي جمع عينات التدريب لكل فئة من فئات سمات كل نوع ميدانياً باستخدام تقنيات مسح أرضي دقيقة مثل أنظمة (GPS) أو جهاز التحديد العالمي للموقع (DGNSS)

- قم بجمع نقاط أو مضلعات تمثل كل نوع من أنواع غطاء الأرض التي ترغب في تحديدها ميدانياً باستخدام الطريقة التي تفضلها.
- قم بتصدير سمات كل فئة بصيغة Shapefile ، ثم اتبع الإرشادات الواردة في القسم السابق لتحميلها إلى منصة Google Earth Engine (GEE) ودمجها في النص المبرمج الخاص بك.

5 تشغيل ACD

بعد أن تقوم بتعيين جميع المتغيرات الخاصة بك، يمكنك تشغيل **MLACD**

- انقر على زر "تشغيل (Run)" لجعل النص المبرمج الخاص بك يعمل وهو موجود في لوحة النص المبرمج الرئيسية.



ستظهر واجهة المستخدم على الجانب الأيسر من الخريطة، حيث يتعين عليك تحديد تواريخ بداية ونهاية فترة الدراسة، بالإضافة إلى تحديد قيمة حرم (Buffer) الموقع الأثري (إذا لزم الأمر).

تم تنظيم واجهة المستخدم للأداء في ثمان خطوات رئيسية يجب على المستخدمين اتباعها لتقدير التهديدات بشكل فعال ومراقبة الموقع الأثري المحددة مسبقاً.

1.1.5 تحديد تاريخي بدء وانتهاء فترة الدراسة:

الخطوة 1: حدد تاريخي بدء وانتهاء فترة الدراسة التي تهتم بها بالشكل التالي: يوم-شهر-سنة ، مثلا: 2020-01-21 .
ملاحظة مهمة: تم تصميم MLACD لمعالجة صور Sentinel-2 Level-2A المصححة جوياً والمُوحّدة. تعتمد عملية المعالجة على توفر البيانات في منطقة دراستك، ولا يمكن أن تمتد إلى ما قبل عام 2017.

2.1.5 تحديد منطقة عازلة للموقع

الخطوة 2 : حدد المسافة حول كل موقع حيث تريد إجراء التحليل.

- أدخل المسافة بالأمتار، مثلا: 50 أو 100
- لاحظ أن وظيفة منطقة الحرم لن تقبل مسافة صفرية، أي 0.
- إذا كانت مواقعك عبارة عن مضلعات بالفعل ولا تريد منطقة حرم، يجب تحديد عدد عشري صغير، مثلا: 0.1

الخطوة 3: بمجرد تحديد التواریخ ومنطقة الحرم، يجب عليك النقر على زر "تشغيل (Run)" الأول في واجهة المستخدم لتنفيذ المرحلة الأولى من المعالجة.

Monitoring Archaeological Sites using EAMENA MLACD

The Machine Learning Automated Change Detection (MLACD) tool leverages freely available satellite imagery and the high-performance computing capabilities of Google Earth Engine to analyze time-series Sentinel-2 images. By comparing sequential images, the tool detects and determines areas of change, identifying where, when, and what types of changes have occurred within the vicinity of known archaeological sites.

1-Define the start and end dates of the study period

Define the start date in the following format: e.g. 2020-01-21.

Start: YYYY-MM-DD

Define the end date in the following format: e.g. 2023-12-31.

End: YYYY-MM-DD

2-Define the feature buffer distance in meters, e.g. 50m. Note that the buffer function will not accept a null distance; 0 meter in that case you must specify a small decimal fraction number e.g. 0.1m.

Buffer in meters

3-Press the "Run" button to execute the first stage of the processing.

Run

4-Select year for training data

from the drop down menu select a year for training data

5-Choose your Image Dates

from the drop down menu select the First Image Date

from the drop down menu select the Second Image Date

6-Press the second "Run" button to execute the second stage of the processing.

Run

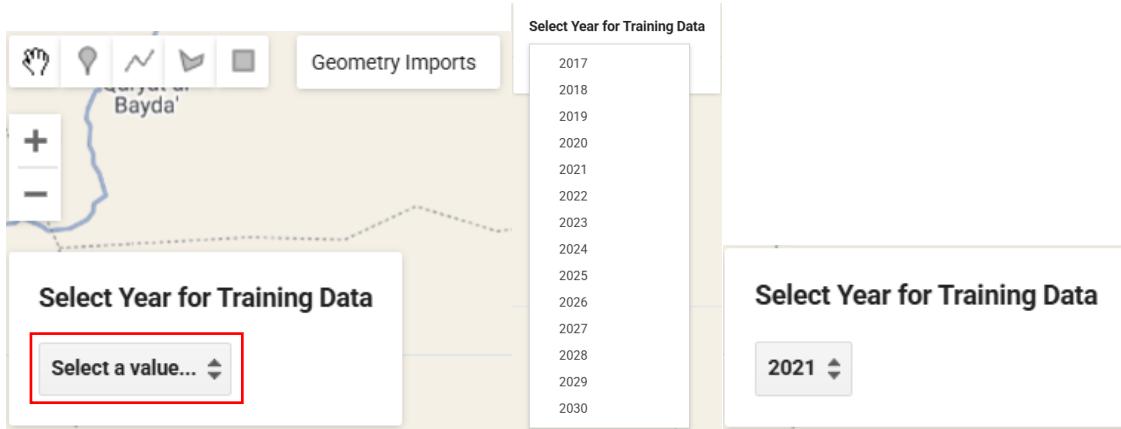
3.1.5 اختيار السنة الخاصة ببيانات التدريب

نظرًا لأن المصنف (Classifier) يتم تدريبه باستخدام كلًّ من عينات التدريب المجمعة ومجموعة الصور الخاصة بسنة معينة، يجب على المستخدم اختيار السنة التي تم خلالها جمع عينات التدريب.

الخطوة 4:

- ستظهر قائمة منسدلة تحتوي على السنوات [2017, 2018, 2019, 2020, 2021, ..., 2023]
- انقر على "Select a value" واختر السنة المناسبة (مثلاً: 2021). سيؤدي ذلك تلقائيًا إلى تصفيية صور Sentinel-2 الخاصة بتلك السنة لاستخدامها كمدخلات في تدريب خوارزمية Random Forest للتصنيف.

تُعد هذه الخطوة ضرورية لضمان أن عينات التدريب ومجموعة الصور تعودان إلى السنة نفسها، مما يحسن دقة التصنيف ويُقلل الأخطاء.




الشكل 5: اختيار سنة بيانات التدريب.

4.1.5 اختيار الصورتين الأولى والثانية للمقارنة

بعد تشغيل المرحلة الأولى، ستظهر قائمة منسدلتان تُظهران تواريخ صور 2-Sentinel المتاحة بناءً على تاريخي البدء والانتهاء اللذين تم تحديدهما في القسم 1.1.5

الخطوة 5: لمراقبة التغيرات بين تاريخين محددين من اهتمامك، اختر من القائمتين المنسدلتين الصورة الأولى Select Second Image والصورة الثانية Select First Image



الشكل 6: اختيار صورتين للمقارنة واكتشاف التغيرات.

بمجرد تحديد التاريخين، يصبح لدى تطبيق **MLACD** جميع المدخلات الالزامية لإجراء تحليل اكتشاف التغيرات.

الخطوة 6: انقر على زر "تشغيل Run" الثاني في واجهة المستخدم الخاصة بـ **MLACD** لتنفيذ المرحلة الثانية من المعالجة (انظر الشكل 6).

يمكنك إعادة تحديد المدخلات بالنقر على زر "إعادة التعيين Reset".

*Optional-Press the "Rest" button to redefine your inputs.

Reset

6 المرحلة الثانية: تصنيف الصور والتحليل


ينتج نظام MLACD عدة مخرجات مختلفة على شكل بيانات مرئية وإحصائية، وتشمل ما يلي:

- خرائط تصنيف الغطاء الأرضي.
- خرائط اكتشاف التغيرات.
- سلاسل زمنية للتصنيف.
- إحصاءات حول الواقع الأثري المهددة والتغيرات التي طرأت عليها.

يتم عرض هذه النتائج في علامة التبويب Layers وفي الـConsole.

1.6 النتائج في علامة التبويب Layers

يمكنك من علامة التبويب Layers في لوحة الخريطة، تفعيل وعرض الطبقات المختلفة التي يتم إنشاؤها تلقائياً بواسطة تطبيق MLACD، انظر (الشكل 7).



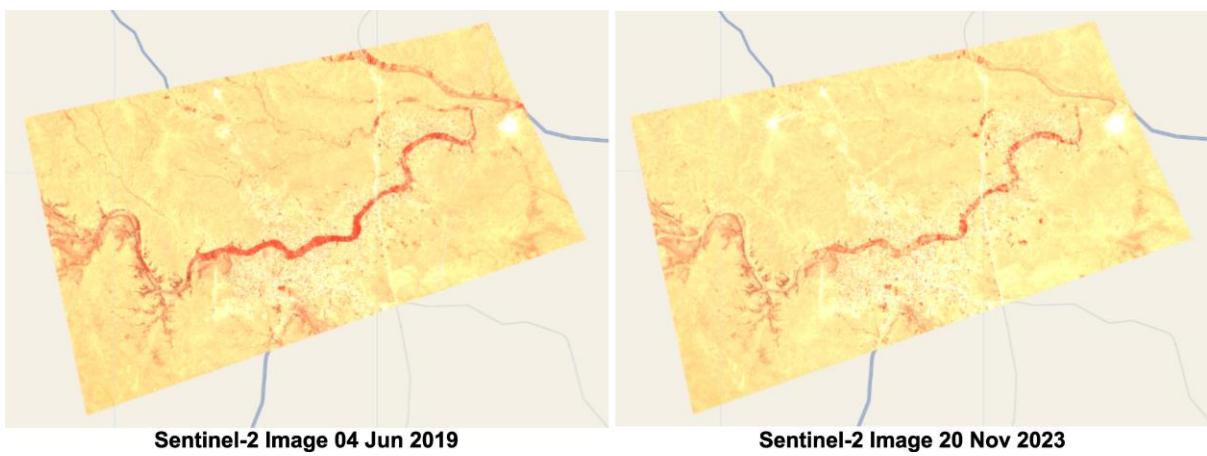
الشكل 7: طبقات مخرجات MLACD في لوحة الخريطة.

يتضمن ذلك ما يلي:


- صور Sentinel-2 للصورتين اللتين تم اختيارهما في الخطوة 5، انظر (الشكل 8).
 - خرائط التصنيف لكلا الصورتين اللتين تم اختيارهما في الخطوة 5، انظر (الشكل 9).
 - خريطة الفرق في التصنيف بين الصورتين المحددتين (انظر الشكل 10).
 - خريطة التغير في التصنيف، والتي تُعيّن قيمة نوع تغير (Change Class Value) جديد لكل نوع من التغيرات من نوع إلى آخر يتم تحديده، مثل التغير من أرض جراء (BareSoil) إلى غطاء نباتي (Vegetation) انظر (الشكل 11).
- يتم حساب قيمة أنواع التغير هذه من خلال تحديد قيمة جديدة لكل تركيبة ممكنة من الأنواع، كما هو موضح في الجدول أدناه، ويتم حسابها تلقائياً بواسطة النص المبرمج.

Class in Image 1 نوع في الصورة 1	Class in Image 2 نوع في الصورة 2	Change Class Value قيمة نوع التغير	Change Class Label تسمية نوع التغير
C1	C1	1	BareSoil_to_BareSoil أرض جراء إلى أرض جراء
C1	C2	2	BareSoil_To_Mountain أرض جراء إلى جبل

C1	C3	3	BareSoil_To_Quarry أرض جراء إلى محجر
C1	C4	4	BareSoil_To_Urban أرض جراء إلى عمران
C1	C5	5	BareSoil_To_Vegetation أرض جراء إلى غطاء نباتي
C2	C1	6	Mountain_To_BareSoil جبل إلى أرض جراء
C2	C2	7	Mountain_To_Mountain جبل إلى جبل
C2	C3	8	Mountain_To_Quarry جبل إلى محجر
...




الشكل 8. صور Sentinel-2 المختارة لاكتشاف التغيرات بينها – الصورة الأولى First Image والصورة الثانية Second Image في لوحة الطبقات Layers panel لعرض كل صورة، تم استخدام الحزمة القريبة من الأشعة تحت الحمراء (B8)، والحزمة الخضراء (B3)، والحزمة الزرقاء (B2)، وهذا يفسر ظهور المناطق المزروعة باللون الأحمر.




الشكل 9: خرائط تصنيف غطاء الأرض للتاريخين المختارين (الصورة المصنفة الأولى First Classified Image ، الصورة المصنفة الثانية Second Classified Image).

• ملاحظة: قد تظهر فراغات في صورك المصنفة لأن مجموعة الصور تمر عبر خطوة الحذف والتنقية (mask filter) التي تزيل أي بكتيرات pixels غائمة أو مظللة من الصورة لتقليل أخطاء التصنيف.



الشكل 10: خريطة التغير الثنائي Binary change بين الصورتين المختارتين الأولى والثانية. مثل اللون الأسود المناطق التي لم يطرأ عليها تغير والقيمة الثنائية لها (0)، بينما يمثل اللون الأحمر المناطق التي حدث فيها تغير بقيمة (1).



الشكل 11: خريطة تغيرات التصنيف تُظهر التغيرات في خصائص غطاء الأرض بين الصورتين المختارتين.



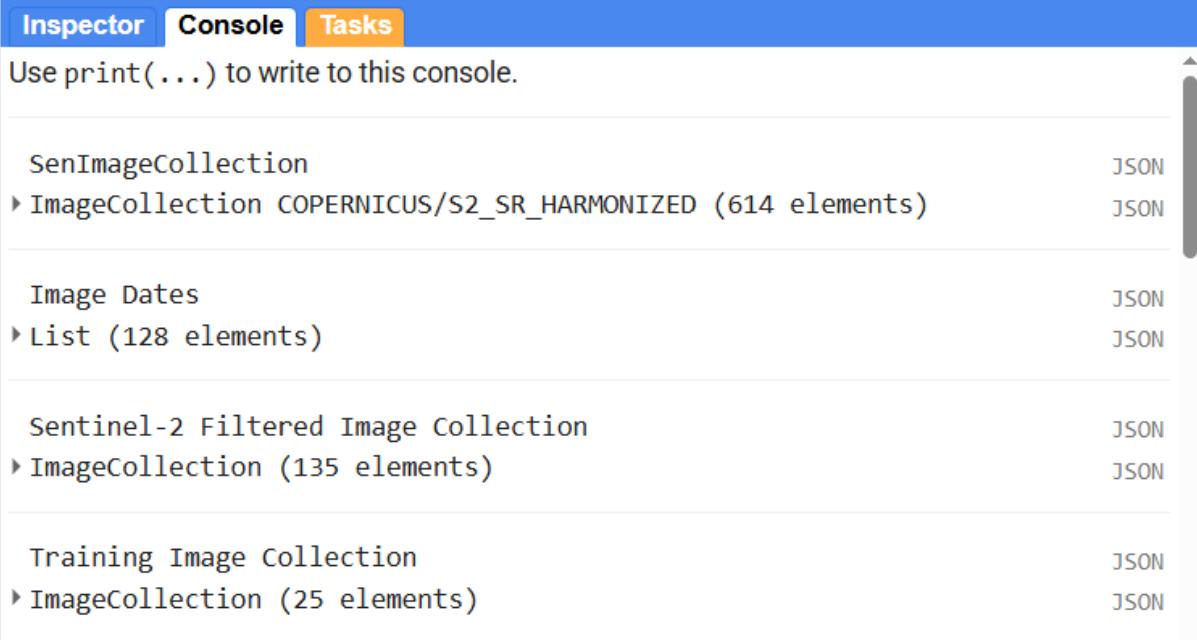
الشكل 12: مفتاح الخريطة لتصنيف اكتشاف التغيرات، تُظهر تسميات انتقال الأنواع والألوان المقابلة المستخدمة لتفسير نتائج التصنيف. تمثل كل تسمية نوعاً محدداً من تغيير في غطاء الأرض.

2.6 النتائج في الـConsole

عند تشغيل النص المبرمج (script)، ستظهر عدة نتائج أخرى في الـConsole. تعرض **SenImageCollection** جميع صور Sentinel-2 وخصائصها التي تداخل مع منطقة الدراسة وال فترة الزمنية المعينة.

توفر مجموعة صور تواریخ الصور **Sentinel-2 Image Dates** أو الملفترة وصور **Training Image Collection** في تدريب مصنف خوارزمية وخصائص الصور المستخدمة في التحليل، والتي تم تتنقية جودتها وتجميعها في صورة فسيفسائية لضمان تغطية كامل منطقة الدراسة.

أما مجموعة صور التدريب **Training Image Collection** فهي تسرد الصور المستخدمة في تدريب مصنف خوارزمية اعتماداً على بيانات سنة التدريب التي يختارها المستخدم **Random Forest**.



Category	Sub-Category	Elements	Action
SenImageCollection	ImageCollection COPERNICUS/S2_SR_HARMONIZED	614 elements	JSON
Image Dates	List	128 elements	JSON
Sentinel-2 Filtered Image Collection	ImageCollection	135 elements	JSON
Training Image Collection	ImageCollection	25 elements	JSON

لتقييم أداء خوارزمية التصنيف الموجّه وقياسها (أي Random Forest) يتم أيضاً إنتاج عدة نتائج دقة في الـ **Console**

- مصفوفة الالتباس (Confusion Matrix) هي جدول يُلخص أداء خوارزمية التصنيف من خلال مقارنة التصنيفات المتوقعة مع البيانات الميدانية الحقيقة (Ground Truth) وتتكون من أربع قيم أساسية: **الموجبة الحقيقة** true positives (TP)، **السلبية الحقيقة** true negatives (TN)، **الموجبة الخاطئة** false positives (FP)، **السلبية الخاطئة** (FN).
 - الدقة الكلية (Overall Accuracy) مقياس يعبر عن مدى نجاح خوارزمية التصنيف في تحديد جميع الفئات داخل مجموعة البيانات بشكل صحيح. يتم حسابها بقسمة إجمالي عدد البكسلات pixels المصنفة بشكل صحيح ($TP + TN$) على إجمالي عدد البكسلات pixels في مجموعة البيانات ($TP + TN + FP + FN$).
 - دقة المستخدم (User Accuracy) أو ما تُعرف أيضاً بدقة (Precision)، وتقيس احتمال أن تكون البكسلات pixels أو الكائنات المصنفة على أنها تنتمي إلى نوع معين تابع فعلياً لذلك النوع في الواقع. ويعني من منظور المستخدم، كم عدد البكسلات pixels المصنفة كنوع X هي في الحقيقة من النوع X . يتم حسابها وفق الصيغة $TP / (TP + FP)$: وتقيم دقة المصنف من وجهة نظر المستخدم. وتعني دقة مستخدم عالية أنه يمكن الوثوق بأن ما تم تصنيفه مثلاً كـ "غطاء نباتي vegetation" هو كذلك بالفعل.
 - دقة المنتج (Producer Accuracy) أو ما تُعرف أيضاً بالاستدعاء (recall) وتقيس مدى قدرة خوارزمية التصنيف على تحديد نوع معين بشكل صحيح نسبةً إلى عدد مرات ظهوره الفعلي في البيانات الميدانية. أي من منظور المنتج (المصنف)، كم عدد بكسلات pixels النوع X الفعلي الذي تم تصنيفه بشكل صحيح. يتم حسابها وفق الصيغة $TP / (TP + FN)$ ؛ وتقيم دقة المصنف من وجهة نظر المنتج. وتشير دقة منتج عالية أن معظم مناطق الغطاء النباتي الفعلية تم تصنيفها بشكل صحيح.
 - درجة (F1 Score) أو مؤشر F1، هي المتوسط التوافقي بين دقة المستخدم (Precision) ودقة المنتج (recall)
- وتتوفر مقياساً متوازناً يأخذ في الاعتبار أخطاء الحذف والإدراج، مما يمنح مؤشراً واحداً لأداء التصنيف لكل نوع محدد.

Inspector **Console** **Tasks**

Classifier Confusion Matrix:

JSON

▶ List (5 elements)

JSON

Classifier Overall Accuracy:

JSON

0.9150450350272434

Classifier Kappa Coefficient:

JSON

0.8893894030872336

Classifier Producer's Accuracy:

JSON

▶ List (5 elements)

JSON

Classifier User's Accuracy:

JSON

▼ List (1 element)

JSON

▶ 0: List (5 elements)

Classifier F-score per class:

JSON

▶ List (5 elements)

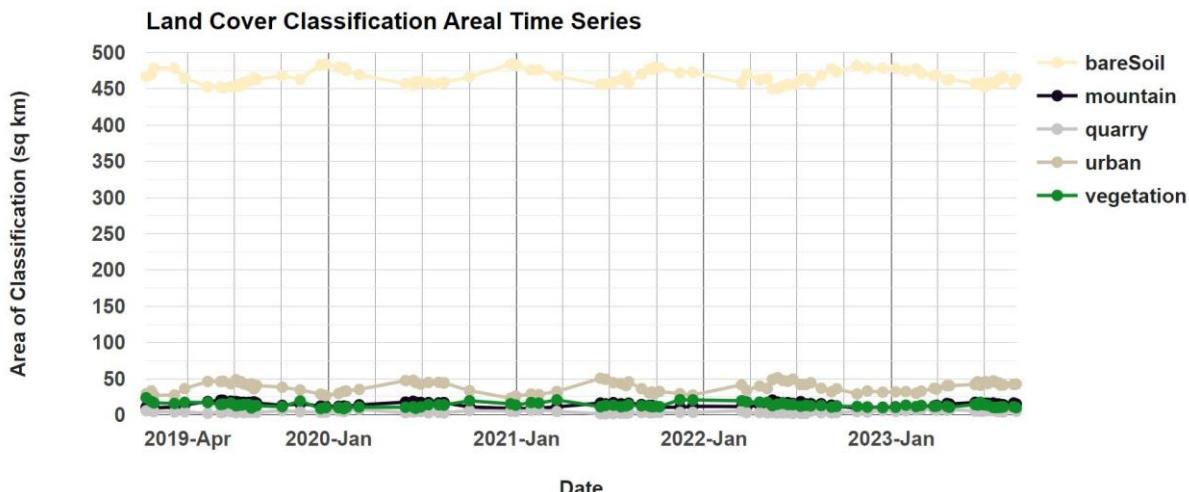
JSON

Inspector **Console** **Tasks**

Press to get the Land Cover Classification Areal Time Series

انقر على زر السلسلة الزمنية لمساحة تصنيف غطاء الأرض (Land Cover Classification Areal Time Series) لعرض مخطط يُظهر تغير مساحة أنواع غطاء الأرض المختلفة عبر مراحل مراحل زمنية.

- يعرض هذا المخطط معلومات إحصائية حول التغيرات في المساحات التي يغطيها كل نوع مراحل مراحل زمنية.
- وتحد هذه المعلومات ذات قيمة كبيرة عند قياس توسيع المناطق العمرانية أو الزراعية داخل منطقة الدراسة.
- في الواقع وفي هذا السياق، تُعد دقة التصنيف عاملًا بالغ الأهمية.



الشكل 13 : السلسلة الزمنية لتغيرات تصنیف غطاء الأرض في بني ولید.

7 المرحلة 3: تحديد التهديدات على المواقع الأثرية

تتعلق النتائج التالية في وحدة التحكم بالمعلومات الإحصائية حول تغيير البكسلات pixels في كل موقع. ويُعد هذا الحساب للتغيير ناتجاً عن طبقة تغيير التصنيف التي تغطي كل حرم (buffer) للموقع.

```

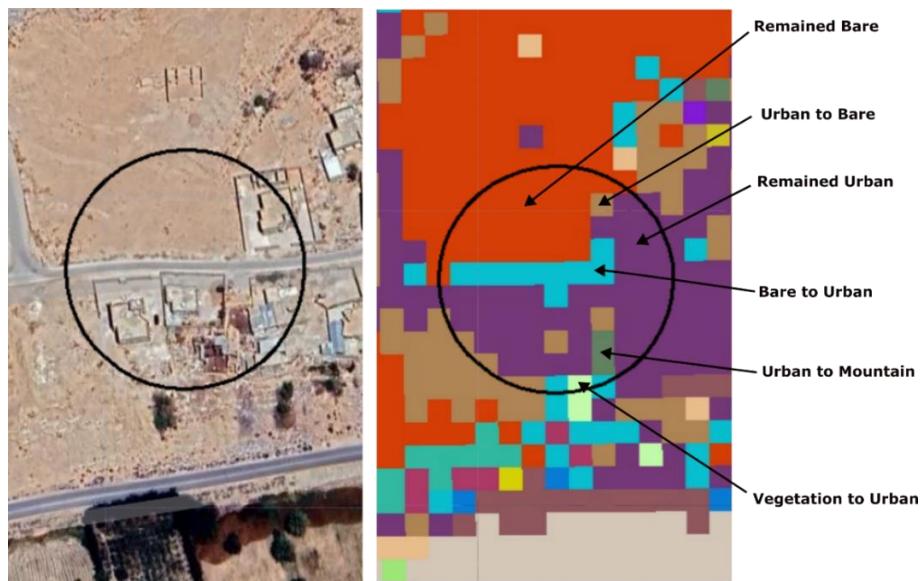
    Inspector Console Tasks
    changesPerSite
    FeatureCollection (211 elements, 111 columns)
    
```

ستجد ضمن **changesPerSite: Feature Collection** قائمة لجميع المواقع التي جرى تحليلها.

- ستجد لكل موقع ضمن الخصائص properties (property) رسمًا بيانيًا يوضح أنواع التغييرات التي تم اكتشافها ضمن حدود منطقة حرم الموقع الأثري، وعدد مرات حدوث هذا التغيير داخل منطقة الحرم، مقاساً بعدد البكسلات pixels.
- سيتم بالإضافة إلى ذلك تحديد التغيير أو التهديد الأكثر سواداً داخل منطقة حرم الموقع عن طريق حساب "الوضعية mode" أو الوتيرة "mode".

```


    Inspector Console Tasks
    FeatureCollection (215 elements, 111 c... JSON
    type: FeatureCollection
    columns: Object (111 properties)
    features: List (215 elements)
    0: Feature 0000000000000000d (Polyg...
    1: Feature 00000000000000001d (Polyg...
    2: Feature 00000000000000001e (Polyg...
    3: Feature 00000000000000001f (Polyg...
    4: Feature 000000000000000020 (Polyg...
    5: Feature 000000000000000021 (Polyg...
    6: Feature 000000000000000022 (Polyg...
    7: Feature 000000000000000023 (Polyg...
    8: Feature 000000000000000024 (Polyg...
    9: Feature 000000000000000025 (Polyg...
    10: Feature 000000000000000026 (Polyg...
    Remained Bare
    Urban to Bare
    Urban to Mountain
    Remained Urban
    Vegetation to Urban
    Bare to Urban
    histogram: Object (6 properties)
    1: 27.098039215686278
    16: 6.03921568627451
    17: 1.9764705882352942
    19: 40.60392156862745
    24: 1.1176470588235294
    4: 10.79607843137255
    layer: BeniUlid-Points
    list: List (107 elements)
    mode: 19
    
```



الشكل 3: خريطة تغيير التصنيف في الموقع الأثري EAMENA-0087287 في بني وليد.

سيتم أيضاً إنشاء رسم بياني في الـ Console لعرض أكثر تغيرات التصنيف تكراراً التي تم العثور عليها داخل منطقة حرم كل موقع، كما يُظهر عدد الموقع وفقاً لأكثر تغير شائع في غطاء الأرض.

- يُوفر ذلك نظرة عامة على أكثر أنواع التهديدات شيوعاً جرى اكتشافها في كلٍ من الموقع التي تمت دراستها.



الشكل 14: رسم بياني يُظهر أكثر تغيرات التصنيف تكراراً تم العثور عليها داخل منطقة الحرم لكل موقع.

1.7 تحليل اكتشاف التغيرات :Change Detection Analysis

الأهم من ذلك، أن الأداة تتضمن ميزة مخصصة لإجراء تحليل اكتشاف التغيرات التي يتم تفعيلها عن طريق تنفيذ الخطوة 7: **تحليل اكتشاف التغيرات Step 7: Change Detection Analysis**. بعد النقر على زر التشغيل الثاني second Run سيظهر عنصر واجهة جديد في واجهة المستخدم يتيح للمستخدم اختيار أنواع التغيرات المحددة التي تهمه، وتتيح هذه الوظيفة إجراء تقصي أكثر تكراراً حول كيفية تأثير تغيرات معينة على الموقع الأثري.

- انقر على أيقونة 'اختيار نوع التغيير (Select Change Type)' ثم اختر من القائمة المنسدلة نوع التغيير الذي ترغب في معرفة تهديده والتقصي عنه؛ ثم انقر على زر 'تحليل التغيير المحدد (Analyse Selected Change)' لإجراء التحليل.

7-Change Detection Analysis

Select Change Type ▾

Analyse Selected Change


تكون النتيجة صورة مقطوعة (masked image) تُبرز فقط البكسلات pixels التي تتوافق مع نوع التغيير المحدد. بالإضافة إلى ذلك، يتم إنشاء طبقة منفصلة لعرض المواقع الأثرية المتأثرة بالتغيير المحدد في غطاء الأرض أو التهديد، استناداً إلى اختيار المستخدم. على سبيل المثال، قد يختار المستخدم نوع التغيير "من أرض جراء إلى مناطق عمران (BareSoil to Urban)" لتحديد المناطق التي تحولت من أرض جراء إلى عمران وتقييم عدد المواقع الأثرية المتأثرة بهذا التغيير.


7-Change Detection Analysis

BareSoil to Urban ▾

Analyse Selected Change

ستظهر في تبويب الطبقات Layers tab صورة اكتشاف التغيير التي تُبرز فقط المناطق أو البكسلات pixels التي تغيرت تصنيفاتها من 'أرض جراء (BareSoil)' إلى عمران (Urban). س يتم إلى جانب ذلك، إضافة طبقة مقابلة تُظهر المواقع الأثرية المتأثرة بهذا التغيير المحدد إلى التبويب نفسه. يمكن استخدام هذه الطبقة لفحص مواقع المواقع المتأثرة ودعم التحليل الميداني لاحقاً.





الشكل 15: خريطة تغيير التصنيف تُظهر المناطق التي تحولت من "أرض جراء (BareSoil) إلى عمران (Urban)" بين التارixinين المحددين، والموقع الأثري الذي تتقاطع مع هذه البكسلات pixels المتغيرة في التصنيف.

سيتم أيضًا عرض عدد الموقع المتاثرة بهذا التغيير في الـConsole. انقر على مجموعة ميزات الموقع المهددة (من الأرض الجرداء إلى العمran) Threatened Sites (BareSoil to Urban) لعرض قائمة بجميع الموقع التي تم فيها الكشف عن بكسل واحد one pixel على الأقل من التغيير المحدد داخل منطقة حرم الموقع.

Inspector **Console** Tasks

Threatened sites count (BareSoil to Urban): JSON
164

Threatened Sites (BareSoil to Urban): JSON
▶ FeatureCollection (164 elements, 111 columns) JSON

لتحديد موقع مهددة بنوع تغير مختلف، اختر ببساطة نوع التغير الجديد في خطوة تحليل اكتشاف التغير Change Detection Analysis ثم انقر على تحليل التغير Analyse Selected Change المحدد مرة أخرى. سيتم عرض النتائج المحدثة في كل من لوحة الطبقات Layers وفي الـConsole كما في السابق. على سبيل المثال، لاكتشاف تغيرات غطاء الأرض من أرض جرداء إلى غطاء نباتي Bare Soil to Vegetation وتحديد الموقع المتاثرة بهذا التغير، اختر من الأرض الجرداء إلى الغطاء النباتي 'BareSoil to Vegetation' واعرض النتائج المقابلة في الـConsole ولوحة الطبقات Layers.

7-Change Detection Analysis


BareSoil to Vegetation

Analyse Selected Change

2.7 تحليل سلسلة زمنية للتصنيف Classification time series analysis


يتيح أيضاً نظام MLACD للمستخدمين دراسة موقع محددة للحصول على نتائج أكثر تفصيلاً حول حالتها وتغيرات غطاء الأرض. ويمكن أن تشمل هذه المواقع الأثرية بالكامل أو مناطق معينة ضمنها تتطلب تقديرًا أدق للتغيرات والتهديدات.

الخطوة 8: يمكن للمستخدم الآن تمرير الفأرة فوق منطقة الدراسة والنقر على أي موقع يهمه لإنشاء رسم بياني لسلسلة زمنية للتصنيف لذلك الموقع النقطي point location. يعرض هذا الرسم البياني في الـ **Console** تغيرات التصنيف أو التهديدات المحتملة على مر الزمن. يتم بالإضافة إلى ذلك، إنتاج رسم بياني لمؤشر NDVI للموقع نفسه لتوضيح تغيرات الغطاء النباتي والاتساع الموسمية. تتم في الوقت نفسه إضافة طبقة نقطية جديدة إلى لوحة الطبقات Layers لتحديد الموقع الذي تم اختياره على وجه الدقة لتحليل السلسلة الزمنية.




الشكل 16: السلسلة الزمنية للتصنيف للموقع (EAMENA-0189408) حيث تم بواسطة نظام MLACD اكتشاف توسيع محتمل للنباتات على الأرجح أنه غير مقصود جاء من مزرعة المجاورة.

اضغط في الـ **Console** على رسم بياني لسلسلة زمنية لمؤشر NDVI (NDVI Time Series Chart) للحصول على رسم بياني للسلسلة الزمنية لمؤشر NDVI للموقع المعنوي.



- قم بالتمرير إلى أسفل الـ **Console** لرؤية الرسم البياني ومعاينته.
- انقر على هذا الزر (⬇️) في أعلى يمين كل رسم بياني، وسيتم فتح عرض كامل للرسم البياني في تبويب منفصل على مما يوفر عرضًا كاملاً للرسم البياني.
- يمكنك النقر على أي من الأزرار الموجودة في أعلى يمين الرسم البياني لتنزيل الرسم البياني بصيغ مختلفة مثل .PNG، SVG، CSV

[Download CSV](#) [Download SVG](#) [Download PNG](#)



الشكل 17: السلسلة الزمنية لمؤشر NDVI للموقع EAMENA-0189408 تُظهر نمو الغطاء النباتي.

يمكننا في المثال أعلاه أن نلاحظ أنه بعد شهر يناير 2021 بفترة، تغير التصنيف في النقطة رقم 1 (Point Location 1) من أرض جراء (BareSoil) إلى غطاء نباتي (Vegetation). يمكن أيضًا عرض النتائج الإحصائية للطبقات المنشأة باستخدام أداة المفتش (Inspector tool) والنقر على الخريطة في أي موقع لعرض قيم الطبقات في الموقع المختار.

8 التصدير Exports

يمكنك من علامة التبويب المهام Tasks في تحرير كود محرك قوقل إيرث GEE Code Editor ، تصدير جميع المعالم (features) وبيانات الصور (raster datasets) التي تم إنشاؤها أثناء المعالجة، بما في ذلك حدود منطقة الدراسة، عينات التدريب، عينات التحقق، خرائط تغيير التصنيف، مناطق التغير، والموقع تحت التهديد.

- بمجرد ظهور مهام التصدير في مدير المهام Task Manager ، انقر على زر التشغيل (Run) بجانب كل معلم أو راستر ترغب في تصديره.

Search or cancel multiple tasks in the [Task Manager](#) or try the [Tasks Page in the Cloud Console](#)

UNSUBMITTED TASKS

 Study_Area	RUN
 Sites	RUN
 Training_Samples	RUN
 validation_samples	RUN
 Sites_buffer	RUN
 changesPerSite	RUN
 First_classifiedImage	RUN
 Second_classifiedImage	RUN
 classification_changes	RUN
 Sites_underThreat_BareSoil_to_Urban	RUN
 Change_Areas_BareSoil_to_Urban	RUN

الشكل 18. تصدير مجموعات البيانات من مدير المهام Task Manager في محرر الكود.

يمكنك حفظ مجموعات البيانات المصدرة في موقع مختلف (مثل EE Assets أو Cloud Storage أو Google Drive) أو (EE Assets) أو Cloud Storage أو Google Drive أو (EE Assets) أو Cloud Storage أو Google Drive وذلك وفقاً لطبيعة سير العمل لديك وسعة التخزين المتاحة.

- حدد صيغة التصدير export format المطلوبة (في حال لم تكن محددة من قبل)، ثم اضغط على زر تشغيل (Run) لبدء عملية التصدير.
- لمزيد من التفاصيل حول تصدير الملفات من GEE ، يُرجى الرجوع إلى: [Google Earth Engine Exporting Guide](#).

Task: Initiate table export

Task name (no spaces) *
Study_Area

DRIVE CLOUD STORAGE EE ASSET FEATURE VIEW ASSET BIGQUERY

Drive folder
Drive folder name or blank for root

Filename *
Study_Area

File format *
SHP

CANCEL RUN

9 خطوات تكييف EAMENA MLACD مع حالات دراسية جديدة Adaptation Stages of the EAMENA MLACD to New Case Studied

1.9 الخطوة الأولى للتكييف: (تحديد البيانات والمدخلات)

First stage of Adaptation: (Define Imports and Inputs)

1. افتح وثيقة شرح خطوات استخدام برنامج EAMENA MLACD.
2. في القسم 3 (الباء) انقر على رمز URL لبني وليد لفتحه في متصفحك.
3. احذف جميع البيانات في النموذج استيراد محرر التعليمات import tab من النص المبرمج للحالة الدراسية لبني وليد.
4. قم بحفظ النص المبرمج كبرنامج نصي جديد باسم الحالة الدراسية الجديدة التي تريدها.
5. هناك ثلاثة مدخلات inputs يجب تحديدها واستيرادها حتى يمكن تشغيل النص المبرمج بشكل صحيح وهي منطقة الدراسة training sample، والموقع الأثري archaeological sites، ومجموعات بيانات عينات التدريب study area لجميع أنواع غطاء الأرض datasets.
6. قم بتحميل ملف shapefile حدود منطقة الدراسة Study_Area أو قم بتحديث وإنشاء شكل جديد باستخدام أداة رسم الأشكال الهندسية Geometry Tool في GEE. اتبع نفس التعليمات الواردة في القسم 1.4 لإنشاء منطقة دراسة جديدة.
7. قم بتحميل ملف shapefile الخاص بالموقع الأثري archaeological Sites أو استخدم أداة Geometry Tool لإنشاء طبقة جديدة للموقع، ويجب تعريف شكلها الهندسي المضلع باسم "FeatureCollection". اتبع التعليمات نفسها الواردة في القسم 2.4 حول إنشاء منطقة دراسة جديدة.
8. كخطوة تحضيرية، يمكنك في منطقة دراستك الجديدة فحص نوع غطاء الأرض الذي يمكن تمييزه بصرياً، ثم تحديد الانواع أو الميزات المختلفة في منطقة دراستك.
9. أضف أو اجمع عينات التدريب training samples للحالة الدراسية الخاصة بك (على سبيل المثال، جراء Bare، مبان Buildings، أشجار Trees، رمال Sand، مياه Water). اتبع التعليمات نفسها الواردة في القسم 2.3.4 لتحديد عينات التدريب الجديدة.

2.9 المرحلة الثانية من عملية التكييف (تكييف المتغيرات في النص المبرمج)

Second Stage of Adaptation (Adaptation of the Variables in the Script)

10. عدل وحرر عينات التدريب ومتغيرات التصنيف في النص المبرمج وفقاً لأنواع غطاء الأرض في حالة الدراسة الجديدة، وذلك باتباع التعليمات نفسها الواردة في القسم 1.3.4

```

22 // // Define the training samples datasets, colours and labels for each class in your case study
23 var trainingClasses = [
24   {TrainingSample: BareSoil, color: '#ffec3', label: 'BareSoil'}, // class 1
25   {TrainingSample: Mountain, color: '#170821', label: 'Mountain'}, // class 2
26   {TrainingSample: Quarry, color: '#c7c6c5', label: 'Quarry'}, // class 3
27   {TrainingSample: Urban, color: '#cdc2a8', label: 'Urban'}, // class 4
28   {TrainingSample: Vegetation, color: '#118b29', label: 'Vegetation'}, // class 5
29 ]; //Add and define additional training samples (e.g., TS: Water, color: '#2591ff', label: 'Water') or remove any class

```

- الآن أصبح النص الجديد المبرمج جاهزاً للتنفيذ باتباع الخطوات الواردة ابتداءً من القسم 5 فصاعداً.

10 التحرير أو التعديل المتقدم في النص المبرمج Advanced Editing on the Script

يمكن لمستخدمي الاستشعار عن بعد المتقدمين إجراء العديد من التعديلات الإضافية لتكييف نص MLACD مع منطقة اهتمامهم الخاصة. على سبيل المثال:

- تعديل نسبة الغيوم : يمكن ضبط حد أدنى لنسبة الغطاء السحابي للتحكم في عدد الصور التي يتم الوصول إليها. تؤدي النسبة المنخفضة إلى تقليل عدد الصور لكنها تضمن مشاهد أكثر وضوحاً، بينما يؤدي رفع النسبة إلى تضمين عدد أكبر من الصور، وقد ينتج عن ذلك اختيار صور تحتوي على غطاء سحابي أعلى مما قد يؤدي إلى أخطاء في التصنيف.

```
var SenImageCollection = ee.ImageCollection("COPERNICUS/S2_SR_HARMONIZED")
    .filterDate(startDateValue, endDateValue)
    .filterBounds(Study_Area)
    .filter(ee.Filter.lt('CLOUD_COVERAGE_ASSESSMENT', 0.5))
    .map(function(img){
        return img.select(homogeneousBands);
});
```

- تحسين مصنف خوارزمية فورست (Optimizing the Random Forest Classifier) لتعزيز دقة نموذج التدريب والخرايط المصنفة، قم بضبط المعلمات الفائقة (hyperparameters) لمصنف خوارزمية فورست ، مثل: عدد الأشجار، الحد الأدنى لعدد العينات في كل عقدة ورقية، ونسبةأخذ العينات الجزئي (subsampling ratio)

```
553 // Train the Random Forest classifier using the combined training samples
554 var trainedClassifier = ee.Classifier.smileRandomForest({
555     numberofTrees: 100,
556     variablesPerSplit: null,
557     minLeafPopulation: 5,
558     bagFraction: 0.6,
559     maxNodes: null,
560     seed: 0
561 }).train({
562     features: monthlyTrainingSamples,
563     classProperty: 'landcover',
564     inputProperties: finalBands
565 });
```

- تحسين كمية عينات التدريب وتوزيعها (Optimizing the quantity and distribution of training samples) عبر جميع أنواع غطاء الأرض يمكن أن يعزز بشكل كبير دقة التصنيف من خلال ضمان تمثيل قوي للتباين الطيفي داخل كل نوع.

```
278 //*****
279 // Merge the training samples into one feature collection
280 var sampleDatasetFC = ee.FeatureCollection(trainingSets).flatten();
281 // print('sampleDatasetFC', sampleDatasetFC);
282 // Convert the training samples feature collection into an image
283 var sampleDatasetFCImage = ee.Image().byte().paint(sampleDatasetFC, 'landcover').rename('landcover');
284 // Collect 100 training samples for each class using the stratified sample function
285 var StratifiedSampleDataset = sampleDatasetFCImage.stratifiedSample({
286     numPoints: 1500,
287     classBand: 'landcover',
288     region: Study_Area,
289     scale: 10,
290     classValues: [0,1,2,3,4,5,6,7,8,9],
291     classPoints: [200, 200, 200, 200, 200, 200, 200, 200, 200, 200],
292     dropNulls: true,
293     geometries: true
294 });
295 // print (StratifiedSampleDataset, 'StratifiedSampleDataset');
296 Map.addLayer(StratifiedSampleDataset, {}, 'Stratified Sample Dataset', false);
297 // Training/Validation Split
298 var StratifiedSampleDatasetRandom = StratifiedSampleDataset.randomColumn();
299 var training_samples = StratifiedSampleDatasetRandom.filter(ee.Filter.lt('random', 0.7));
300 var validation_samples = StratifiedSampleDatasetRandom.filter(ee.Filter.gte('random', 0.7));
```